

# Come hanno lavorato gli agenti nell'ultima run PathMNIST

Documento esplicativo del workflow HAT-MedMNIST

Run del 2 ottobre 2026  
Analisi degli artefatti e dei log di esecuzione

v2/runs/pathmnist\_20261002T083530607044Z

## Sommario

Il documento ricostruisce il lavoro degli agenti nella run indicata, seguendo il percorso dai dati al dossier finale. Per ciascun ruolo distingue informazioni disponibili, decisioni, artefatti prodotti e controllo del Reviewer. La ricerca è stata eseguita sul seed 42; la configurazione vincente è stata congelata e allenata nuovamente sui seed 47 e 72. Il risultato è un workflow completo con accuracy media del 92,64%, ma con warning aperti e comportamento OOD instabile. Completamento della pipeline e accettazione del progetto sono quindi due esiti distinti.

## Indice

|          |                                                                          |          |
|----------|--------------------------------------------------------------------------|----------|
| <b>1</b> | <b>Il principio di collaborazione</b>                                    | <b>3</b> |
| 1.1      | Le condizioni della run . . . . .                                        | 3        |
| <b>2</b> | <b>La sequenza operativa</b>                                             | <b>3</b> |
| <b>3</b> | <b>Gli agenti che preparano il problema</b>                              | <b>4</b> |
| 3.1      | Ingestion: rendere disponibili dati e riferimenti . . . . .              | 4        |
| 3.2      | Profiling / Ambiguity: descrivere dati e incertezze . . . . .            | 4        |
| 3.3      | Prior-Art Scout: trasformare fonti in ipotesi . . . . .                  | 4        |
| <b>4</b> | <b>Gli agenti che progettano l'esperimento</b>                           | <b>5</b> |
| 4.1      | Preprocessing: proporre la rappresentazione iniziale . . . . .           | 5        |
| 4.2      | Data Audit: autorizzare l'accesso al training . . . . .                  | 5        |
| 4.3      | Architecture Research: formulare indicazioni, non un vincitore . . . . . | 5        |
| <b>5</b> | <b>La decisione centrale: ricerca e congelamento</b>                     | <b>6</b> |
| 5.1      | Model Search sul seed 42 . . . . .                                       | 6        |
| 5.2      | Frozen Configuration sui seed 47 e 72 . . . . .                          | 6        |
| 5.3      | Quale agente non è intervenuto . . . . .                                 | 6        |

|          |                                                                  |          |
|----------|------------------------------------------------------------------|----------|
| <b>6</b> | <b>Gli agenti che eseguono e misurano</b>                        | <b>6</b> |
| 6.1      | Training: eseguire la scelta congelata . . . . .                 | 6        |
| 6.2      | Evaluation: aprire il test per la misura finale . . . . .        | 7        |
| 6.3      | Abstention / OOD: decidere quando rinviare . . . . .             | 7        |
| <b>7</b> | <b>Reviewer e Orchestrator: controllo e gestione dei warning</b> | <b>7</b> |
| <b>8</b> | <b>Reporting, baseline e accettazione</b>                        | <b>8</b> |
| <b>9</b> | <b>Che cosa chiarisce questa run sul lavoro degli agenti</b>     | <b>8</b> |
| <b>A</b> | <b>Mappa delle evidenze</b>                                      | <b>8</b> |

# 1 Il principio di collaborazione

Gli agenti non si passano direttamente oggetti attraverso chiamate reciproche. Il punto di scambio è un **Blackboard**: ogni agente legge gli artefatti necessari e pubblica i propri risultati. Gli artefatti hanno un tipo, una versione, un produttore e un checksum. I dati pesanti, come immagini, checkpoint e predizioni, sono conservati in file referenziati dagli artefatti.

L'**Orchestrator** stabilisce l'ordine di esecuzione. Dopo ogni fase invoca il **Reviewer**, che restituisce un rapporto di anomalie. Le decisioni e i passaggi sono registrati in `decision_log.jsonl`; richieste e risposte del reasoning sono conservate in `blobs/reasoning/`.

**Ibrido** significa che il calcolo di dati, training e metriche è eseguito dal codice, mentre alcuni agenti usano il modello locale `qwen3.8` per proporre o motivare decisioni. Il nome del modello è registrato; il digest dei suoi pesi è assente. Non è quindi possibile ricostruire la sua identità esatta dal solo manifest.

## 1.1 Le condizioni della run

| Aspetto          | Configurazione effettiva                               |
|------------------|--------------------------------------------------------|
| Dataset          | PathMNIST, nove classi, immagini RGB $28 \times 28$    |
| Split            | 89.996 train; 10.004 validation; 7.180 test            |
| Ripetizioni      | Seed 42, 47 e 72; dataset completo                     |
| Ricerca          | Otto trial, tre round, solo sul seed 42                |
| Budget dei round | 3, 6 e 9 epoche; training finale fino a 15 epoche      |
| Reasoning        | Ollama locale, modello richiesto; chiamate sequenziali |
| Letteratura      | Estratti integrati; ricerca online disattivata         |
| Ablation         | Non eseguite: <code>ablation_suite=false</code>        |

## 2 La sequenza operativa

Sul seed 42 il flusso osservato è:

1. Ingestion: carica il dataset e registra gli split.
2. Profiling / Ambiguity: descrive i dati e i rischi di ambiguità.
3. Prior-Art Scout: costruisce un brief di ipotesi con fonti.
4. Preprocessing: sceglie una prima rappresentazione.
5. Data Audit: verifica i dati prima del training.
6. Architecture Research: formula indicazioni per la ricerca.
7. Model Search: allena e confronta candidati usando la validation.
8. Training: riallena la configurazione selezionata.
9. Evaluation: misura il risultato sul test.
10. Abstention / OOD: calibra l'astensione e valuta le corruzioni.
11. Reporting: raccoglie il dossier, poi aggiornato dopo il confronto baseline.

Il Reviewer interviene fra gli stadi. Nei seed 47 e 72, il punto 7 è sostituito da **Frozen Configuration**: riprende il vincitore senza una nuova ricerca. Le fasi iniziali di profiling e reasoning vengono comunque eseguite; non possono cambiare la configurazione finale congelata.

### 3 Gli agenti che preparano il problema

#### 3.1 Ingestion: rendere disponibili dati e riferimenti

**Informazioni e azione** Riceve dataset, seed e opzioni di caricamento. Carica PathMNIST preservando gli split ufficiali e registra forma, classi, dimensioni e riferimenti degli indici selezionati. In questa run non è attivo alcun sottocampionamento.

**Consegna al Blackboard** Pubblica `dataset_manifest` e `blob_raw_dataset`, con il riferimento a `blobs/raw_dataset_v001.npz`. Il manifest permette agli agenti successivi di conoscere il problema senza ricostruire il caricamento.

**Esito del controllo** Il Reviewer approva l'ingestion nei tre seed. Caricare e registrare il test non significa renderne disponibili le metriche alla ricerca: il suo uso valutativo è separato dalle decisioni iniziali.

#### 3.2 Profiling / Ambiguity: descrivere dati e incertezze

**Informazioni e azione** Usa train e validation per calcolare distribuzione delle classi e statistiche delle immagini. Il rapporto di sbilanciamento train è circa 1,63; le distribuzioni train/validation sono molto simili. I canali RGB hanno medie circa (0,741; 0,533; 0,706) e deviazioni standard (0,124; 0,177; 0,124).

L'LLM interpreta queste informazioni e segnala sovrapposizioni plausibili: adipose/background, smooth muscle/stroma, debris e frammenti cellulari, oltre a patch che possono contenere tessuti diversi. Queste sono **ipotesi di ambiguità**, non errori di annotazione dimostrati.

**Consegna al Blackboard** Produce `data_profile`, con statistiche, rischi e provenienza del reasoning. La valutazione delle ambiguità non usa il risultato del test. Il campo test imbalance presente nel profilo non va interpretato come una misura effettiva: il test non è stato profilato in questa fase.

#### 3.3 Prior-Art Scout: trasformare fonti in ipotesi

**Informazioni e azione** Legge il contesto del dataset e tre estratti integrati relativi a ViT, Compact Transformers e MedMNIST v2. In questa run non esegue una ricerca web. Le fonti hanno origine `curated_excerpt`; il primo brief è `bundled`, e i successivi utilizzano la cache.

Sul seed 42 propone quattro idee: patch transformer, tokenizzazione convoluzionale compatta, scelta della granularità delle patch e training sensibile allo sbilanciamento. Le etichetta come ipotesi da validare. Propone anche una composizione di augmentation e una specifica di compact transformer. Sono proposte, non codice generato ed eseguito.

**Consegna al Blackboard e gate** Pubblica `prior_art_brief`, snapshot delle fonti, `extension_gate_report` e `approved_extensions`. Le nuove proposte restano `pending_review`: non diventano automaticamente nuove famiglie eseguibili. Le primitive già integrate restano utilizzabili senza approvare una nuova estensione.

Il compact transformer provato dalla ricerca appartiene al registro esistente: **non dimostra la promozione della nuova specifica dello Scout**. Il Reviewer segnala correttamente che estratti citabili non dimostrano retrieval online né tutte le inferenze scientifiche sviluppate a partire da essi.

## 4 Gli agenti che progettano l'esperimento

### 4.1 Preprocessing: proporre la rappresentazione iniziale

**Informazioni e decisione** Legge il profilo e le ipotesi bibliografiche. Sceglie standardizzazione train-only e una prima combinazione di augmentation: `hflip`, `brightness`, `rotate90`. Mantiene immagini RGB e risoluzione del benchmark.

**Consegna e aggiornamento successivo** Pubblica la prima versione di `representation_plan`, `split_manifest` e del blob dei dati preparati. Questa decisione è un punto di partenza: la ricerca può proporre una combinazione diversa all'interno dei limiti ammessi. Il vincitore sostituisce `rotate90` con `rotate180`; il Blackboard conserva entrambe le versioni e rende esplicito il cambiamento.

### 4.2 Data Audit: autorizzare l'accesso al training

**Informazioni e controlli** Il controllo è deterministico: verifica split ufficiali, indici, immagini, label, forme, valori e statistiche train-only; controlla la disgiunzione train/validation. Nei tre seed l'audit passa e non trova sovrapposizioni.

**Consegna e significato** Produce `data_audit_report`. Model Search e Training richiedono un audit passato prima di iniziare. Un warning del Reviewer su documentazione o interpretazione può restare aperto anche quando l'audit dei dati è positivo: non sono lo stesso controllo.

### 4.3 Architecture Research: formulare indicazioni, non un vincitore

**Informazioni e azione** Combina profilo, rappresentazione e prior art in un documento di indicazioni su famiglie, tokenizzazione, regolarizzazione e rischi. Sul seed 42 il reasoning considera promettente il compact transformer.

**Consegna e limite** Pubblica `architecture_research`. Questo artefatto guida le proposte del search agent, ma **non seleziona il modello finale**. L'esito della ricerca sarà una ResNet18: la preferenza teorica non prevale sulle misure di validation. Le raccomandazioni bibliografiche sono inoltre fallibili e non costituiscono una prova sperimentale delle relative affermazioni.

## 5 La decisione centrale: ricerca e congelamento

### 5.1 Model Search sul seed 42

L'agente legge metadati di training, indicazioni precedenti e risultati di validation già prodotti. L'LLM propone candidati; il codice impone schema, limiti, copertura delle famiglie e budget. La ricerca è quindi una collaborazione fra proposte motivate e vincoli deterministici.

| Trial                               | Epoche | Accuracy validation |
|-------------------------------------|--------|---------------------|
| Compact transformer                 | 3      | 94,5522%            |
| Residual CNN bilanciata             | 3      | 97,1811%            |
| ResNet18 conservativa               | 3      | 97,8908%            |
| Tiny CNN regolarizzata              | 6      | 92,0832%            |
| Vision transformer                  | 6      | 96,1515%            |
| ResNet18 conservativa               | 6      | 99,0804%            |
| ResNet18 conservativa               | 9      | 99,1104%            |
| ResNet18 più larga, class weighting | 9      | <b>99,4002%</b>     |

Tabella 1: Trial effettivamente completati. I budget diversi non consentono un confronto a parità di costo fra famiglie.

I trial sono training separati: riprovare una configurazione con più epoche non implica proseguire automaticamente dal precedente checkpoint. La scelta considera i trial al budget massimo; usa accuracy entro la tolleranza dichiarata e macro-F1 per il ranking. Le metriche del test sono escluse. Il vincitore è `resnet18_wider_cw`.

L'agente pubblica `search_plan`, artefatti dei singoli trial, `search_report`, `train_config` e `best_configuration`; aggiorna anche la rappresentazione definitiva e salva `best_config_v001.yaml`.

### 5.2 Frozen Configuration sui seed 47 e 72

L'agente riprende il `best_configuration` del seed 42 e cambia il seed di training. Ricostruisce i dati preparati e il file YAML locale, senza fare altri trial. Questo è il meccanismo che rende confrontabili le tre ripetizioni del modello selezionato.

Il valore di validation 99,4002% riportato nella selezione dei tre seed rimane quello del trial originale. Le nuove validation finali appartengono invece ai rispettivi training. I file YAML locali hanno hash diversi perché cambia il seed; gli altri parametri sono uguali.

### 5.3 Quale agente non è intervenuto

`ExperimentDesignAgent` è disponibile per il percorso senza ricerca iterativa, ma **non è stato eseguito in questa run**. La scelta è stata affidata a Model Search, poi ripresa da Frozen Configuration. Le ablation della rappresentazione, pur implementate come procedura, non sono state attivate.

## 6 Gli agenti che eseguono e misurano

### 6.1 Training: eseguire la scelta congelata

Legge dati preparati, audit e configurazione finale. Allena il modello con Lightning fino al budget di 15 epoche; registra la storia delle metriche e conserva il checkpoint scelto sulla validation. Non

propone una nuova architettura né adatta la scelta al test.

Produce `train_result` e il riferimento del modello. La migliore epoca è 15, 15 e 14 nei tre seed; tutti completano 15 epoche. Le migliori accuracy di validation finali sono rispettivamente 99,4702%, 99,6002% e 99,5602%.

## 6.2 Evaluation: aprire il test per la misura finale

Usa il checkpoint selezionato e produce probabilità, logits, predizioni e metriche del test: accuracy, macro-F1, balanced accuracy, AUC, matrice di confusione e risultati per classe. Pubblica `prediction_artifact` e `evaluation_report`.

| Seed | Accuracy | Macro-F1 | Balanced accuracy |
|------|----------|----------|-------------------|
| 42   | 92,2981% | 0,898925 | 0,901332          |
| 47   | 92,1448% | 0,898564 | 0,897181          |
| 72   | 93,4680% | 0,917116 | 0,915932          |

Il test resta fuori dalla ricerca, ma il suo risultato viene successivamente letto per valutazione, revisione e reporting. Il divario validation/test rimane di circa 6–7,5 punti. Lo stroma associato al tumore ha recall fra 56,53% e 64,37%: il risultato aggregato non elimina questa debolezza.

## 6.3 Abstention / OOD: decidere quando rinviare

L’agente confronta max-softmax ed entropia predittiva usando la validation e corruzioni gaussiane controllate. Sceglie lo score con migliore AUROC medio sulla validation e calibra una soglia per coprirne circa l’80%. Applica poi score e soglia al test senza cambiarli in base al risultato.

Produce `abstention_report`, curve rischio/copertura, probabilità delle corruzioni e `human_review_queue`. La coda registra indici dei campioni, predizione, confidenza e motivo del rinvio.

| Seed | Score       | Coverage | Acc. accettati | Rinvii |
|------|-------------|----------|----------------|--------|
| 42   | Entropia    | 67,37%   | 97,42%         | 2.343  |
| 47   | Max-softmax | 65,29%   | 97,57%         | 2.492  |
| 72   | Max-softmax | 68,70%   | 97,67%         | 2.247  |

L’astensione funziona sui campioni puliti nel senso di ridurre l’errore fra quelli accettati. Non garantisce però protezione OOD: sul seed 47 l’AUROC medio è 0,3938 e alla corruzione forte è circa 0,0018. Il modello predice background con alta confidenza e accetta quasi tutti i casi corrotti. Il problema è già osservabile sulla validation; il selettore sceglie il migliore fra due score insufficienti e non restituisce un esito esplicito “nessuno score idoneo”.

Il Reviewer segnala questo fallimento. Il seed 72 passa il criterio AUROC minimo implementato, ma accetta circa metà dei casi con rumore forte. Queste misure riguardano un proxy di corruzione, non OOD clinico generale. La coda dimostra un handoff predisposto: non una revisione umana conclusa.

## 7 Reviewer e Orchestrator: controllo e gestione dei warning

Il Reviewer combina invarianti deterministiche con un esame LLM degli artefatti disponibili. Produce rapporti `anomaly_*` e distingue `continue`, `revise` e `stop`. Un finding critico deterministico può bloccare il flusso; le affermazioni LLM non sufficientemente dimostrate rimangono advisory.

**revise** non equivale a una modifica già eseguita. L'Orchestrator può ripetere lo stadio se è disponibile una remediation sicura; altrimenti registra **review\_unresolved** e promuove lo stadio con warning. Nei log compaiono 5, 6 e 2 eventi di questo tipo sui seed 42, 47 e 72. La run non mostra un ciclo di correzione che risolva tutti i rilievi.

Fra i rilievi osservati figurano fonti integrate invece di retrieval web, inferenze che eccedono le citazioni, debolezza dello stroma, digest LLM assente e fallimento OOD del seed 47. Alcuni commenti sulle proposte di augmentation richiedono interpretazione: una ricetta nuova pending non impedisce di usare singolarmente primitive già integrate.

**Il Reviewer segnala e rende tracciabile il problema; non è un agente che ripara autonomamente il modello.** L'Orchestrator permette il completamento operativo con warning. La procedura di accettazione finale mantiene però questi problemi aperti.

## 8 Reporting, baseline e accettazione

Reporting assembla **dossier.json**, registro degli artefatti e stato del workflow. Dopo la prima chiusura, il runner esegue una baseline convenzionale sullo stesso dataset e seed, pubblica **baseline\_report** e **comparison\_report**, richiama il Reviewer e aggiorna il dossier.

**La baseline è una procedura del runner, non un ulteriore agente di reasoning.** L'accuracy media è 82,99%, contro 92,64% della pipeline. Il vantaggio di 9,65 punti riguarda però un sistema con 6,29 milioni di parametri contro una Tiny CNN di 5.433 parametri, oltre a rappresentazione e costi diversi. Non misura isolatamente il contributo degli agenti.

La procedura di accettazione associa requisiti a evidenze e produce **acceptance\_report**. Tutti i seed risultano tecnicamente completi, ma non pronti per l'accettazione e senza evidenza TRL 7 completa. Passa ora il requisito di ripetizione con configurazione congelata. Restano assenti ablation, prova di retrieval online, fault evidence sul codice esatto, replay completo, mitigazioni approvate e sign-off indipendente.

## 9 Che cosa chiarisce questa run sul lavoro degli agenti

La collaborazione osservata è coerente con la separazione fra proposta, esecuzione e controllo. Gli agenti iniziali descrivono il problema; quelli di reasoning suggeriscono rappresentazioni e candidati; il search produce evidenze di validation; training ed evaluation eseguono e misurano; il Reviewer rende visibili limiti e incongruenze; reporting mantiene il dossier finale.

La decisione architetturale più importante è stata presa sul seed 42 e conservata nei due successivi. L'accuracy migliora rispetto alla run precedente, ma l'instabilità OOD mostra che congelare gli iperparametri non basta a garantire stabilità di confidenza e rifiuto.

Questa run documenta quindi **un workflow agentico operativo e auditabile**, con decisioni effettive dell'LLM e risultati misurati. Non dimostra ancora che tutte le motivazioni siano scientificamente corrette, che l'OOD sia affidabile o che l'orchestrazione sia superiore a una ricerca convenzionale a parità di spazio e budget.

## A Mappa delle evidenze

I riferimenti seguenti sono relativi alla directory della run indicata in apertura. Gli artefatti versionati sono in **seed\_\*/artefacts/**.

| Domanda                                | Evidenza principale                                      |
|----------------------------------------|----------------------------------------------------------|
| Quali opzioni sono state usate?        | run_configuration, run_manifest                          |
| Che cosa è avvenuto e in quale ordine? | seed_*/decision_log.jsonl                                |
| Che cosa ha detto l'LLM?               | seed_*/blobs/reasoning/                                  |
| Quali dati e statistiche?              | dataset_manifest, data_profile                           |
| Quali fonti e proposte?                | prior_art_brief, extension_gate_report                   |
| Quali scelte di input?                 | Versioni di representation_plan                          |
| Quali candidati e vincitore?           | Artefatti trial_*, search_report, best_configuration     |
| Quale training finale?                 | train_result, best_config_v001.yaml                      |
| Quali risultati e rinvii?              | evaluation_report, abstention_report, human_review_queue |
| Quali rilievi restano?                 | Rapporti anomaly_*, acceptance_report.json               |
| Quale riepilogo fra seed?              | experiment_summary.json                                  |

La ricostruzione si basa sugli artefatti e sui log della run. Il codice corrente è stato consultato per interpretare i meccanismi, ma ha un hash diverso dal codice registrato nella run: non sostituisce lo snapshot originale. Le verifiche successive sono conservate in v2/audits/pathmnist\_20261002T083530607044Z/; non sono eventi eseguiti dagli agenti durante la run. Il presente documento non modifica gli artefatti storici.